

## 02 Linear Predictor

Logistic Regression(逻辑回归)

# 本章目录

2

**01** 分类问题

**02** **Sigmoid**函数

**03** 逻辑回归求解

# 1.分类问题

3

**01** 分类问题

**02 Sigmoid**函数

**03** 逻辑回归求解

# 分类问题

4

## 监督学习的最主要类型

标签离散

### ✓ 分类 ( Classification )

- ✓ 身高1.85m , 体重100kg的男人穿什么尺码的T恤 ?
- ✓ 根据肿瘤的体积、患者的年龄来判断良性或恶性 ?
- ✓ 根据用户的年龄、职业、存款数量来判断信用卡是否会违约 ?

输入变量可以是离散的 , 也可以是连续的。

# 分类问题


5

## 二分类

我们先从用蓝色圆形数据定义为类型1，其余数据为类型2；

只需要分类1次

步骤：①->②



二分类


# 分类问题

6

## 多分类

我们先定义其中一类为类型1（正类），其余数据为负类（rest）；接下来去掉类型1数据，剩余部分再次进行二分类，分成类型2和负类；如果有 $n$ 类，那就需要分类 $n-1$ 次

步骤：①->②->③->.....



One-vs-All (One-vs-Rest)

一对多 (一对余)

## 2.Sigmoid函数

7

**01** 分类问题

**02** Sigmoid函数

**03** 逻辑回归求解


## 2.Sigmoid函数

8

### Sigmoid 函数

$\sigma(z)$ 代表一个常用的逻辑函数 ( logistic function ) 为S形函数 ( Sigmoid function )

$$\text{则 : } \sigma(z) = g(z) = \frac{1}{1+e^{-z}} \quad z=w^T x + b$$



当 $\sigma(z)$ 大于等于0.5时 , 预测  $y=1$

当 $\sigma(z)$ 小于0.5时 , 预测  $y=0$



## 2.Sigmoid函数

9

线性回归的函数  $h(x) = z = w^T x$  , 范围是 $(-\infty, +\infty)$ 。

而分类预测结果需要得到 $[0,1]$ 的概率值。

在二分类模型中，事件的几率odds：事件发生与事件不发生的概率之比为 $\frac{p}{1-p}$ ，

称为事件的发生比（ the odds of experiencing an event ）

其中 $p$ 为随机事件发生的概率， $p$ 的范围为 $[0,1]$ 。

取对数得到： $\log \frac{p}{1-p}$ ，而 $\log \frac{p}{1-p} = w^T x = z$

求解得到： $p = \frac{1}{1+e^{-w^T x}} = \frac{1}{1+e^{-z}}$


注意：若表达式  $h(x) = z = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n + b = w^T x + b$ ，则 $b$ 可以融入到 $w_0$ ，即： $z = w^T x$

## 2.Sigmoid函数

10

将 $z$ 进行逻辑变换： $g(z) = \frac{1}{1+e^{-z}}$

$$\begin{aligned} g'(z) &= \left( \frac{1}{1+e^{-z}} \right)' \\ &= \frac{e^{-z}}{(1+e^{-z})^2} \\ &= \frac{1+e^{-z}-1}{(1+e^{-z})^2} \\ &= \frac{1}{(1+e^{-z})} \left( 1 - \frac{1}{(1+e^{-z})} \right) \\ &= g(z)(1-g(z)) \end{aligned}$$



# 3.逻辑回归求解

11

**01** 分类问题

**02 Sigmoid**函数

**03** 逻辑回归求解

# 3.逻辑回归求解

12

假设一个二分类模型：

$$p(y = 1|x; w) = h(x)$$

$$p(y = 0|x; w) = 1 - h(x)$$

则：

$$p(y|x; w) = (h(x))^y (1 - h(x))^{1-y}$$

逻辑回归模型的假设是： $h(x) = g(w^T x) = g(z)$

其中 $z = w^T x$ ，逻辑函数 ( **logistic function**) 公式为：

$$g(z) = \frac{1}{1+e^{-z}}, \quad g'(z) = g(z)(1 - g(z))$$

注意：若表达式  $h(x) = z = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n + b = w^T x + b$ ，则 $b$ 可以融入到 $w_0$ ，即： $z = w^T x$

# 3.逻辑回归求解

13

## 损失函数

$$L(\hat{y}, y) = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y})$$

$\hat{y}$  表示预测值  $h(x)$

$y$  表示真实值

为了衡量算法在全部训练样本上的表现如何，我们需要定义一个算法的代价函数，算法的代价函数是对 $m$ 个样本的损失函数求和然后除以 $m$ ：

## 代价函数

$$J(w) = \frac{1}{m} \sum_{i=1}^m L(\hat{y}^{(i)}, y^{(i)}) = \frac{1}{m} \sum_{i=1}^m (-y^{(i)} \log \hat{y}^{(i)} - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}))$$

### 3.逻辑回归求解

14

求解过程：

似然函数为：  $L(w) = \prod_{i=1}^m P(y^{(i)}|x^{(i)}; w) = \prod_{i=1}^m (h(x^{(i)}))^{y^{(i)}} (1 - h(x^{(i)}))^{1-y^{(i)}}$

似然函数两边取对数，则连乘号变成了连加号：

$$l(w) = \log L(w) = \sum_{i=1}^m (y^{(i)} \log(h(x^{(i)})) + (1 - y^{(i)}) \log(1 - h(x^{(i)})))$$

代价函数为：

$$J(w) = -\frac{1}{m} l(w) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log(h(x^{(i)})) + (1 - y^{(i)}) \log(1 - h(x^{(i)})))$$

# 3.逻辑回归求解

15

梯度下降求解过程：

$$w_j := w_j - \alpha \frac{\partial J(w)}{\partial w}$$

$$J(w) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log(h(x^{(i)})) + (1 - y^{(i)}) \log(1 - h(x^{(i)})))$$

$$\frac{\partial}{\partial w_j} J(w) = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$$\text{则：} w_j := w_j - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

### 3.逻辑回归求解

16

求解过程： $\frac{\partial}{\partial w_j} J(w) = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_j^{(i)}$ 的推导过程：

$$J(w) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log(h(x^{(i)})) + (1 - y^{(i)}) \log(1 - h(x^{(i)})))$$



$$\begin{aligned} & y^{(i)} \log(h(x^{(i)})) + (1 - y^{(i)}) \log(1 - h(x^{(i)})) \\ &= y^{(i)} \log\left(\frac{1}{1 + e^{-w^T x^{(i)}}}\right) + (1 - y^{(i)}) \log\left(1 - \frac{1}{1 + e^{-w^T x^{(i)}}}\right) \\ &= -y^{(i)} \log(1 + e^{-w^T x^{(i)}}) - (1 - y^{(i)}) \log(1 + e^{w^T x^{(i)}}) \end{aligned}$$



### 3.逻辑回归求解

17

求解过程： $\frac{\partial}{\partial w_j} J(w) = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_j^{(i)}$  的推导过程：

$$\begin{aligned} \frac{\partial}{\partial w_j} J(w) &= \frac{\partial}{\partial w_j} \left( -\frac{1}{m} \sum_{i=1}^m \left( -y^{(i)} \log(1 + e^{-w^T x^{(i)}}) - (1 - y^{(i)}) \log(1 + e^{w^T x^{(i)}}) \right) \right) \\ &= -\frac{1}{m} \sum_{i=1}^m \left( -y^{(i)} \frac{-x_j^{(i)} e^{-w^T x^{(i)}}}{1 + e^{-w^T x^{(i)}}} - (1 - y^{(i)}) \frac{x_j^{(i)} e^{w^T x^{(i)}}}{1 + e^{w^T x^{(i)}}} \right) \\ &= -\frac{1}{m} \sum_{i=1}^m (y^{(i)} - h(x^{(i)})) x_j^{(i)} \\ &= \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_j^{(i)} \end{aligned}$$

# 3.逻辑回归求解

18


正则化：目的是为了**防止过拟合**

$$J(w) = \frac{1}{m} \sum_{i=1}^m \left[ -y^{(i)} \log(h(x^{(i)})) - (1 - y^{(i)}) \log(1 - h(x^{(i)})) \right] +$$


正则化项

$$\frac{\lambda}{2m} \sum_{j=1}^n w_j^2$$


当  $\lambda$  的值开始上升时，降低了方差。



没有正则化，过拟合



正则化过度，欠拟合



适当的正则化

逻辑回归 (Logistic Regression) 与一般线性分类模型 (Linear Classification, 如使用Sign (\*) 函数的分类模型) 的区别?

- [1] HOSMER D W, LEMESHOW S, STURDIVANT R X. Applied logistic regression[M]. New Jersey: Wiley New York.2000.
- [2] Andrew Ng. Machine Learning[EB/OL]. Stanford University,2014.  
<https://www.coursera.org/course/ml>
- [3] 李航. 统计学习方法[M]. 北京: 清华大学出版社,2019.
- [4] Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning[M]. New York: Springer,2001.
- [5] CHRISTOPHER M. BISHOP. Pattern Recognition and Machine Learning[M]. New York: Springer,2006.
- [6] Stephen Boyd, Lieven Vandenberghe, Convex Optimization[M]. Cambridge: Cambridge University Press, 2004.
- [7] TIBSHIRANI R. Regression selection and shrinkage via the lasso[J]. Journal of the Royal Statistical Society Series B, 1996, 58(1): 267–288.